영양소 2개 추출: 파인튜닝 전 베이스라인 결과

A.X-4.0-Light(bf16, 4090 서버) · dev 216문장 · 시스템 프롬프트에 규칙 예시 10개만 제공 · 학습 없음 · 2026-11-04

무엇을 쟀나
문장 하나를 주고 A.X가 **영양소 2개와 각각의 높음/낮음**을 답하게 했습니다. 모델이 본 것은 "문장"과 "규칙 예시 10개"뿐이고, 정답은 채점할 때만 썼습니다. 이 점수가 **파인튜닝 전 기준점**이며, 나중에 파인튜닝한 모델을 같은 dev로 재서 비교합니다.
완전 정답 = 문장의 쌍(성분+방향) 2개를 모두 맞힘 · **쌍 정확도** = 전체 쌍(216×2=432개) 중 맞힌 비율

1. 한눈에 보기

14.4%
완전 정답률 (31/216)

48.6%
쌍 정확도 (210/432)

82.9%
1개 이상 맞힌 문장 (179/216)

구분	점수	
첫 번째 영양소 (성분1+방향1)	161/216 = 74.5%	
두 번째 영양소 (성분2+방향2)	49/216 = 22.7%	
성분을 찾았을 때 방향도 맞은 비율	210/215 = 97.7%	

- **방향(높음/낮음)은 문제없습니다.** 성분만 찾으면 방향은 거의 다 맞아요.
- **약점은 두 번째 영양소**입니다. 첫 번째는 문장에 단서가 있어서 74.5%, 두 번째는 단서가 적어서 22.7%예요.
- 목표는 "프롬프트로 50~60%"였습니다. **쌍 정확도(48.6%)로 보면 목표에 가깝고, 완전 정답률(14.4%)로 보면 많이 낮습니다.** 어느 점수를 목표로 할지 팀에서 정해야 해요.
- 점수가 낮다는 건 **파인튜닝으로 올릴 여지가 크다**는 뜻이기도 합니다.

2. 어디서 맞고 어디서 틀렸나

상황	정답 2개	완전	첫째	둘째
S016 성장기 간식	단백질↑, 열량↑	3/20	20/20	3/20
S017 혼밥 보충	단백질↑, 나트륨↓	0/20	20/20	0/20
S034 회식 다음 날	나트륨↓, 지방↓	7/20	7/20	13/20
S035 땀 흘린 뒤	나트륨↑, 당류↑	0/20	12/20	0/20
S2008 걷기 여행	탄수화물↑, 열량↑	1/17	17/17	1/17
S2018 밥 먹으면 배 빵빵	탄수화물↓, 열량↓	0/17	7/17	0/17
S2027 기름진 걸로 오래 버티기	지방↑, 열량↑	5/17	16/17	5/17
S2035 어르신 간식	지방↓, 나트륨↓	4/17	15/17	4/17
S2045 수유 중	열량↑, 단백질↑	6/17	7/17	15/17
S2053 건강검진 전 체중	열량↓, 지방↓	1/17	10/17	4/17
S2062 아이 달래기	당류↑, 열량↑	0/17	17/17	0/17
S2072 운동 중 안 단 음료	당류↓, 열량↓	4/17	13/17	4/17

첫 번째 영양소는 대부분 상황에서 잘 맞히는데, 두 번째는 거의 못 맞히는 상황이 많습니다 (S017, S035, S2018, S2062는 두 번째가 0건).

정답 성분	전체	첫째일 때	둘째일 때
단백질	96.5%	100%	88.2%
지방	67.6%	91.2%	45.9%
탄수화물	70.6%	70.6%	(없음)
당류	55.6%	88.2%	0%
나트륨	29.9%	47.5%	10.8%
열량	21.6%	50.0%	12.4%

나트륨과 열량을 가장 못 찾습니다. 정답에 열량이 139번 나오는데 모델은 34번만 답했고, 대신 단백질↑(97번)과 탄수화물↑(87번)을 많이 답했어요.

출력 이상	건수
성분 6개 밖의 값을 씀 (fiber 16, calcium 6, vitamins 1, water 1)	23문장
JSON 파싱 실패 / 1개만 답함	1건 / 1건
3개 이상 답함 / 같은 성분 두 번 답함	0건 / 0건

3. 왜 이런 결과가 나왔나 (원인 네 가지)

① 두 번째 영양소의 정답 근거가 문장에 없다 (가장 큰 원인)
정답은 상황마다 정해진 조합이고, 두 번째 영양소는 **제안한 임시 안**입니다. 문장만 보고는 알 수 없는 경우가 많아요.

상황 / 문장	정답	A.X의 답
S2062 "달래줄 사탕 뭐 있어?" (17문장 전부 같은 답)	당류↑, 열량↑	당류↑, 탄수화물↑
S017 "맨날 라면만 먹었더니 몸이 안 좋은 것 같아"	단백질↑, 나트륨↓	단백질↑, 식이섬유↑
S2035 "부모님 간식으로 지방 적은 걸 찾고 있어요"	지방↓, 나트륨↓	지방↓ (1개만 답함)

사탕에 "당류↑ + 탄수화물↑"이라고 답한 것은 오히려 합리적인 답입니다. **모델이 틀렸다기보다 정답 조합을 정하는 기준이 아직 없는 것**에 가까워요.

② 규칙 예시가 답에 그대로 복사된다
규칙 1(운동 후 → 고단백, 저지방)과 형식 예시에 나온 `단백질↑, 지방↓` 조합이 정답과 상관없는 문장에도 자주 나옵니다 (S017, S034, S2018, S2072 등).

③ 성분 6개를 지키지 않는다
식이섬유, 칼슘, 비타민, 물을 답한 문장이 23개입니다. 프롬프트에 "6개 중에서만"이라는 제한을 강하게 적지 않았기 때문이에요. 이건 프롬프트 한 줄이나 파인튜닝으로 쉽게 고칠 수 있습니다.

④ 이미 알려진 라벨 문제가 점수를 깎는다

- 학습 데이터에 **나트륨 높음**이 한 줄도 없어서 S035(땀 흘린 뒤)는 완전 정답 0/20입니다.
- 회식 다음 날(S034), 수유(S2045), 건강검진 전 체중(S2053)처럼 문장에 성분 단서가 약한 상황이 있습니다.

중요한 주의: 두 번째 영양소가 상황마다 제각각이면 파인튜닝을 해도 **처음 보는 상황의 두 번째 영양소**는 잘 못 맞힐 수 있습니다. 모델이 배울 "규칙"이 없기 때문이에요. 그래서 아래 4번 결정이 가장 중요합니다.

4. 앞으로 할 일

순서	할 일	누가
1	**두 번째 영양소를 정하는 기준 결정** (아래 표)	팀 전체
2	1번에서 정한 기준으로 상황표의 성분2/방향2를 고치고, dev/train을 다시 만들기	다이영 + Claude
3	train에 **나트륨 높음** 상황 추가 (또는 서비스에 필요 없으면 dev의 S035 제외)	팀 결정 후 담당자
4	시스템 프롬프트에 "성분은 6개 중에서만 답한다"는 한 줄만 추가해서 **베이스라인 재측정**. 이후에는 프롬프트를 고정	다이영 + Claude Code
5	파인튜닝용 데이터(train) 변환과 검증 → 4090에서 QLoRA 파인튜닝	다이영 + Claude Code
6	같은 dev와 같은 채점으로 파인튜닝 전/후 비교 → 마지막에 test를 한 번만 측정	다이영

1번에서 정할 것: 두 번째 영양소를 어떻게 정할까

	A. 짝 규칙표	B. 상황마다 문장 근거로	C. 영양소 1개로 돌아가기
방식	첫 번째 영양소마다 기본 짝을 정함 (예: 단백질↑ → 지방↓)	상황의 이유에 맞게 두 번째를 정하고, 문장에 그 단서를 포함시킴	지금까지처럼 1개만 추출
장점	규칙이 명확해서 모델이 배우기 쉬움. 파인튜닝 효과가 가장 잘 보임	자연스러운 조합. 사람이 보기에 설득력 있음	가장 단순하고 점수도 높음 (이전 82~83%)
단점	상황에 안 맞는 짝이 생길 수 있음	문장을 새로 만들거나 고쳐야 해서 작업량이 큼	"2개 추출"이라는 목표에서 벗어남

제안: 먼저 **A안(짝 규칙표)**을 시도합니다. 상황표만 고치면 문장은 그대로 쓸 수 있어서 작업이 가장 적고, 결과가 좋으면 그대로 진행, 부족하면 B안으로 보강하는 순서가 안전해요.
기억할 점: 이번 점수는 임시 정답 기준이라 확정 점수가 아닙니다. 기준을 정한 뒤 다시 재서 최종 기준점으로 삼아요.
결과 파일: 4090 서버 `~/LLM_CU_project_daiyoung/dev_2nut_baseline/` (`rows.csv` 문장별 결과, `wrong.csv` 틀린 185문장)